Nedelja 7: izveštaj pre/posle

Autor: Uroš Milutinović (samostalan rad) **Demonstraciju na Sesiji 2 vodi:** Uroš Milutinović **Promena:** M5, filter važeće verzije (`CURRENT_ONLY = True`)
Commitovi: `ee583f3` početno stanje → `2ceaced` specifikacija → `45b8172` promena (obavezni deo)
Datum: 2026-10-17 **Šablon:** `docs/sablon-izvestaj-pre-posle.md` (napravljen prema zahtevima zadatka, jer zvanični šablon nije bio dostavljen)

> Ovaj paket sadrži samo M5 checkpoint 45b8172. Napredni eksperimenti su odvojeni u glavnom repozitorijumu.

1. Početna provera

- `python -m pytest` : **18 passed** (`evidence/pytest-before.txt`)
- `python -m src.eval_runner --out results/before.json` : **6/12**
- `eval_set_sha256` : `afe46db1e75a0b85bb5c9a93b6763e3b96e5cd7b289e12da6d2671e4d8650064`

```
ID   Category                  Expected Got     Hit  Fact  CitPrec Pass
-------------------------------------------------------------------------
E01  supported                 answer   answer  yes  yes   0.50    PASS
E02  supported                 answer   answer  yes  yes   0.50    PASS
E03  supported                 answer   answer  yes  yes   0.50    PASS
E04  chunk-boundary            answer   answer  yes  no    1.00    FAIL
E05  paraphrase                answer   answer  no   no    0.00    FAIL
E06  versioned                 answer   answer  no   no    0.00    FAIL
E07  supported                 answer   answer  yes  yes   1.00    PASS
E08  supported                 answer   answer  yes  yes   0.50    PASS
E09  chunk-boundary            answer   answer  yes  no    1.00    FAIL
E10  unsupported               refuse   answer  -    -     0.00    FAIL
E11  unsupported-near-domain   refuse   answer  -    -     0.00    FAIL
E12  unsupported               refuse   refuse  -    -     -       PASS

Passed: 6/12
Behaviour accuracy: 0.83
Retrieval hit rate (supported): 0.78
Mean citation precision (answered): 0.45
```

2. Dokumentovani propusti (najmanje dva)

Ocene su iz `top_k` polja u `results/before.json` .

ID	Očekivano	Dobijeno	Tip propusta
E06	Odgovor iz `hb-03` (2026, current): „3 days per week“	Citira `hb-02-chunk-0` (0.48) i `hb-02-chunk-1` (0.40), verziju 2024 koja je `superseded` , sa „2 days per week“. Važeći `hb-03-chunk-0` ima 0.37 i ispada iz top-2.	Retrieval (pogrešno rangiranje po verziji), posledica je pogrešan odgovor
E04, **E09**	Citat sa „5 business days“ iz `hb-01`	Pravi dokument je nađen (Hit = yes, CitPrec 1.00), ali su citirani `hb-01-chunk-0` i `hb-01-chunk-2` . Činjenica je u `hb-01-`	Chunkovanje

ID	Očekivano	Dobijeno	Tip propusta
		`chunk-1`, koji je tek peti po oceni. Sečenje na 140 znakova deli rečenicu („…set up by IT staff with I your files…“).	
E10	Odbijanje (cena akcija nije u priručniku)	Odgovara sa 0.059 iz `hb-09-chunk-1` i `hb-05-chunk-1`, koji dele samo česte reči.	Pogrešan odgovor (prag odbijanja 0.02 je prenizak)
E11	Odbijanje (parental leave ne postoji u korpusu)	Odgovara sa 0.17 iz `hb-07` (Annual leave), jer deli reči „leave“ i „policy“.	Pogrešan odgovor (pitanje blisko domenu)
E05	`hb-01`, „5 business days“	„notebook computer“ nema leksičko preklapanje sa „laptop“; vrh je `hb-06` (Onboarding). Hit = no.	Retrieval (parafraza)

Uz to, E01, E02, E03 i E08 imaju CitPrec 0.50 jer se uvek citiraju oba top-2 rezultata, i kada je drugi nebitan (propust citata, dopuna).

3. Specifikacija jedne promene

Napisana i commitovana pre izmene koda (`docs/change-spec.md`, commit `2ceaced`).

Polje	Sadržaj
Propust	E06: sistem citira zastarelu politiku rada od kuće (2024, `superseded`) i daje „2 days per week“ umesto „3 days per week“.
Hipoteza	Tekstovi 2024. i 2026. su skoro isti, a stari chunk-ovi su kraći, pa `lexical_score` (preklapanje / dužina chunk-a) daje višu ocenu staroj verziji. Pipeline ne koristi metapodatak `status`.
Promena	Implementirati `CURRENT_ONLY` u `searchable_chunks` (izbaciti `status == "superseded"`) i uključiti ga u `config.py`.
Očekivani efekat	E06 → PASS sa `hb-03-chunk-0`, CitPrec 1.00. Hit rate 0.78 → 0.89. E01–E03 ostaju PASS (dopunski citat `hb-02` zamenjuje drugi chunk).
Rizik regresije	Pitanja o istoriji ili starim pravilima više nisu odgovoriva (eval to ne pokriva). Dopunski citat za E01–E03 može postati drugi nebitan chunk. Za E04, E05, E09, E10 i E11 ne očekujem promenu.
Provera	`pytest`, ista eval komanda sa `--out results/after.json`, `eval_compare`, ručni CLI za E06.

4. Primenjena promena

`evidence/change.diff` (`git diff ee583f3 HEAD -- src tests`):

```
--- a/src/config.py
-CURRENT_ONLY = False
+CURRENT_ONLY = True
--- a/src/retrieval.py
 def searchable_chunks(chunks: list[Chunk]) -> list[Chunk]:
     if config.CURRENT_ONLY:
-        raise NotImplementedError("CURRENT_ONLY = True is not implemented yet.")
+        return [chunk for chunk in chunks if chunk.status != "superseded"]
     return chunks
```

Dodat je i jedan test mehanike (`test_current_only_excludes_superseded_chunks` u `tests/test_retrieval.py`). Test ne menja ponašanje sistema, samo proverava da filter radi u oba položaja. Kod koji računa metrike i `eval/eval_set.json` nisu menjani.

5. Ponovno merenje

- `python -m pytest`: **19 passed** (`evidence/pytest-after.txt`)
- `python -m src.eval_runner --out results/after.json`: **7/12**, isti `eval_set_sha256`

```
ID   Category                 Expected Got     Hit  Fact  CitPrec Pass
-------------------------------------------------------------------
E01  supported                answer   answer  yes  yes   0.50    PASS
E02  supported                answer   answer  yes  yes   0.50    PASS
E03  supported                answer   answer  yes  yes   0.50    PASS
E04  chunk-boundary           answer   answer  yes  no    1.00    FAIL
E05  paraphrase               answer   answer  no   no    0.00    FAIL
E06  versioned                answer   answer  yes  yes   1.00    PASS
E07  supported                answer   answer  yes  yes   1.00    PASS
E08  supported                answer   answer  yes  yes   0.50    PASS
E09  chunk-boundary           answer   answer  yes  no    1.00    FAIL
E10  unsupported              refuse   answer  -    -     0.00    FAIL
E11  unsupported-near-domain  refuse   answer  -    -     0.00    FAIL
E12  unsupported              refuse   refuse  -    -     -       PASS

Passed: 7/12
Behaviour accuracy: 0.83
Retrieval hit rate (supported): 0.89
Mean citation precision (answered): 0.55
eval_set_sha256: afe46db1e75a0b85bb5c9a93b6763e3b96e5cd7b289e12da6d2671e4d8650064
```

6. Poređenje

`python -m src.eval_compare results/before.json results/after.json` (`evidence/compare.txt`):

```
Fixed (fail -> pass): E06
Regressed (pass -> fail): none
Unchanged: E01, E02, E03, E04, E05, E07, E08, E09, E10, E11, E12

Summary:
  passed: 6 -> 7 (+1)
  total: 12 -> 12 (+0)
  behaviour_accuracy: 0.8333 -> 0.8333 (+0.0)
  retrieval_hit_rate: 0.7778 -> 0.8889 (+0.1111)
  mean_citation_precision: 0.4545 -> 0.5455 (+0.091)

Changed settings:
  CURRENT_ONLY: False -> True
```

Promenjeno je samo jedno podešavanje, pa alat ne upozorava na više promena. Otisak eval skupa je isti, pa je poređenje prihvaćeno.

Ručna provera (E06): `python -m src.cli --question "How many days per week can I work remotely?" --show-retrieved`

- Pre (`evidence/cli-E06-before.txt`): citati `hb-02-chunk-0` i `hb-02-chunk-1`, *Remote work policy (version 2024, superseded)*, tekst „up to 2 days per week“.
- Posle (`evidence/cli-E06-after.txt`): citati `hb-03-chunk-0` (0.3704) i `hb-03-chunk-1` (0.1429), *Remote work policy (version 2026, current)*, tekst „up to 3 days per week“.

To se slaže sa redom E06 u `results/after.json`.

7. Zaključak i regresije

Hipoteza je potvrđena: E06 je popravljen jer zastarela verzija više ne ulazi u pretragu, a nijedno pitanje nije palo. Rast CitPrec (0.45 → 0.55) dolazi samo od E06 (0.00 → 1.00). E01, E02 i E03 ostaju na 0.50.

Regresije: u eval skupu nema nijedne. Promena koja se ne vidi u metrikama: dopunski drugi citat za E01, E02 i E03 je prešao sa `hb-02` na `hb-03` (npr. E01: `hb-02-chunk-0` → `hb-03-chunk-0`). Citat je i dalje nebitan za pitanje, samo iz važeće verzije. To je predviđeno u specifikaciji.

8. Preostala ograničenja (najmanje jedno)

1. **E04 i E09 (chunkovanje):** činjenica „5 business days“ i dalje je u chunk-u koji nije u top-2. Ova promena to nije ni ciljala. Kandidat za sledeću promenu je M1 (sečenje po rečenicama).
2. **E10 i E11 (pogrešan odgovor umesto odbijanja):** prag 0.02 je prenizak. E11 („parental leave“) ima vrh 0.17, više od nekih podržanih pitanja (E02 ima 0.13), pa ni sama kalibracija praga (M3) ne bi rešila E11 bez rizika da se odbiju podržana pitanja.
3. **E05 (parafraza):** leksički retrieval ne zna da je „notebook computer“ isto što i „laptop“. Nijedna stavka iz menija to ne rešava; potrebni su sinonimi, query rewriting ili embeddings.
4. **Dopuna citata:** E01, E02, E03 i E08 i dalje citiraju nebitan drugi chunk (CitPrec 0.50).
5. **Istorijska pitanja:** sa `CURRENT_ONLY = True` sistem više ne može da odgovori na pitanje „kakva je bila politika 2024?“. Eval skup to ne meri. Bolja buduća varijanta bila bi da se verzija ne izbacuje nego koristi pri rangiranju, ili da se filter uključuje po pitanju.

9. Pregled para

Status: projekat sam 19. 10. 2026. poslao drugom polazniku na pregled, ali odgovor nije stigao do slanja izveštaja. Zato komentar para ovde nije unet; nije izmišljen niti zamenjen tekstom AI asistenta.

Umesto toga, tri pitanja pregleda sam proverio sam, uz ponovljiv dokaz:

1. **Da li je promena jedna i odgovara specifikaciji?** Da: diff menja samo `CURRENT_ONLY` i telo `searchable_chunks`, a `eval_compare` prijavljuje jedno promenjeno podešavanje. Specifikacija (`2ceaced`) prethodi promeni (`45b8172`).
2. **Da li rezultat podržava zaključak?** Da: isti otisak eval skupa, E06 fail → pass, nijedna regresija. Paket je ponovo raspakovan u prazan folder: 19 testova prolazi, eval ponovo daje 7/12, identično sačuvanom `after.json`.
3. **Da li je izostavljena regresija ili ograničenje?** Promena dopunskog citata za E01–E03 i gubitak istorijskih pitanja navedeni su u odeljcima 7 i 8.

Ako komentar para stigne posle roka, biće dodat ovde bez menjanja ostatka izveštaja.

9.1. Moj osvrt na sopstveni rad — Uroš Milutinović

U obaveznom delu uradio sam jednu promenu: uključio sam filter važeće verzije dokumenata. Pre izmene sam zapisao specifikaciju, očekivani efekat i rizike, a zatim sam implementirao promenu i proverio rezultat na istih 12 pitanja.

Rezultat je porastao sa 6/12 na 7/12, bez regresija na tom skupu. Na pitanju E06 sistem je ranije citirao zastarelu politiku sa 2 dana rada na daljinu. Posle promene citira važeću politiku iz 2026. sa 3 dana. Proverio sam rezultate pre i posle, poređenje, diff, CLI odgovor i citate. Evaluacioni skup i kod za metrike ostali su isti.

Ograničenja sam naveo u izveštaju. Ostaju problemi sa chunkovanjem, parafrazama i odbijanjem pitanja za koja nema odgovora u korpusu. Filter isključuje zastarele dokumente, pa ograničava i odgovaranje o istorijskim pravilima. Zato zaključujem da sam popravio izbor važeće verzije na dokumentovanom primeru, dok ostali problemi zahtevaju zasebne promene i nova merenja.

Celokupan rad uradio sam samostalno, uz pomoć AI asistenta u analizi, implementaciji i pripremi teksta. Lično sam proverio navedene rezultate i dokaze. Napredne eksperimente prikazao sam odvojeno od obaveznog M5 eksperimenta.

Status nezavisnog pregleda drugog para naveden je u odeljku 9.

10. Korišćenje AI-ja

Claude Code (AI asistent) je korišćen da pročita kod checkpointa, pokrene testove i eval, izdvoji ocene iz `top_k` radi dijagnoze propusta, napiše nacrt specifikacije i implementira filter sa testom, a u naprednom delu i promene A1–A4 (a kasnije G1–G8, rundu 2 i slepi test 5, odeljak 18), kontrolnu proveru i automatski pregled koda (odeljak 12). AI asistent je takođe pisao i testirao B1–B5c; Codex je uradio analizu i ispravke C1–C6 (odeljak 14), kao i kontrolisane D1–D6 eksperimente (odeljak 15). „Ručni pregled“ u naprednim eksperimentima označava pregled asistenta, ne nezavisnu ljudsku proveru. Sve tvrdnje su proverene merenjem, a ne na osnovu reči asistenta: `results/before.json` i `results/after.json` su napravljeni istom komandom, `eval_compare` potvrđuje isti otisak i samo jedno promenjeno podešavanje, a E06 je ručno proveren preko CLI-ja pre i posle (izlazi u `evidence/`). Lična potvrda autora: ja, Uroš Milutinović, lično sam proverio sve što je navedeno u ovom izveštaju. Moja provera obuhvata dokumentovane propuste, specifikaciju i diff promene, sačuvane rezultate pre/posle i njihovo poređenje, CLI odgovor i citate za E06, kao i navedene regresije i ograničenja. Ova potvrda ne predstavlja nezavisni pregled drugog para niti pojedinačne ljudske oznake za napredne skupove.

11. Doprinos

Član	Doprinos
Uroš Milutinović	Celokupan rad na projektu — Uroš Milutinović.

Dokazi

Svi obavezni dokazi su u `evidence/`: `before.json`, `after.json`, `compare.txt`, `change.diff`, CLI izlazi za E06 i izlazi testova pre/posle. Specifikacija je u `docs/change-spec.md` (commit `2ceaced`), implementacija u commitu `45b8172`. Napredni eksperimenti (odeljci 12 i dalje u glavnom repozitorijumu) nisu deo ovog paketa.