Nedeljni izveštaj, Nedelja 7

Polaznik: Uroš Milutinović
Projekat: izvor. (kontrolisano poboljšanje RAG sistema)
Način rada: samostalno
Demonstraciju vodi: Uroš Milutinović
Pregled para: projekat sam poslao drugom polazniku na pregled (odeljak 9 izveštaja pre/posle)

Šta sam uradio

Prošao sam kroz propuste početnog sistema i za svaki zapisao konkretno pitanje iz eval skupa. Za obavezni deo izabrao sam M5, filter važeće verzije dokumenata (`CURRENT_ONLY`). Specifikaciju sam commitovao pre bilo kakve izmene koda (`2ceaced`), pa tek onda implementirao promenu (`45b8172`). Ceo projekat sam radio sam, uz AI asistenta kako je opisano u izveštaju.

Rezultat i dokazi

Na istih 12 pitanja rezultat je porastao sa 6/12 na 7/12, bez regresija. Na E06 sistem je ranije vadio staru politiku iz 2024. sa 2 dana rada od kuće, a sada vadi važeću iz 2026. sa 3 dana. Retrieval hit rate je sa 0,7778 porastao na 0,8889, a prosečna preciznost citata sa 0,4545 na 0,5455. Otisak eval skupa je isti pre i posle, a eval skup i kod za metrike nisam dirao.

U paketu su JSON rezultati pre i posle, izlaz poređenja, diff, specifikacija, izlazi testova (18 pre, 19 posle) i CLI izlazi za E06. Napredne eksperimente držim odvojeno u glavnom repou, jer nisu deo ove jedne promene.

Šta sam proverio i moj komentar

Proverio sam sve što je u izveštaju: propuste, specifikaciju i diff, rezultate pre i posle, poređenje, CLI odgovor i citate za E06 i ograničenja. Po mom mišljenju rezultati pokazuju da filter rešava izbor zastarele politike na E06. Ostale probleme sistema ne rešava.

I dalje ostaju problemi sa granicama chunkova, parafrazama, pitanjima na koja korpus nema odgovor i nebitnim drugim citatom. Filter ima i cenu: posle M5 sistem više ne može da odgovori kakva je bila stara politika, a osnovni eval to ne meri. Svaki od ovih problema traži posebnu promenu i novo merenje, pa sam ih rešavao u naprednom delu, odvojeno od M5. Istorijska pitanja sam na kraju rešio filterom koji zavisi od pitanja: na dva nova skupa rezultat je porastao sa 9/20 na 20/20, na dva nova slepa skupa je 16/16, a od postojećih pitanja promenilo se samo jedno, koje je ranije padalo, a sada prolazi. Na kraju sam pojačao zaštitu od napada (lažna premisa o izvoru, zahtevi za skrivenim tekstom): na novom slepom skupu napada rezultat je porastao sa 6/10 na 10/10, bez regresija. Kontekst verzije za pitanja o važećoj verziji sam probao dva puta i oba puta odbio, jer je kvario druga pitanja.

Korišćenje AI-ja

AI mi je pomagao u analizi, pisanju nacrta specifikacije i izveštaja, implementaciji i pokretanju provera. I ovaj tekst sam pisao uz njegovu pomoć. Zaključke sam proverio sam, na sačuvanim rezultatima, u kodu i ručnim pokretanjem CLI-ja.

Plan demonstracije za Sesiju 2

Počeću od propusta na E06, gde sistem odgovara iz zastarele politike. Onda ću pokazati specifikaciju (`2ceaced`), diff promene (`45b8172`), rezultate pre i posle na istom skupu (6/12 → 7/12) i CLI izlaz koji sada citira važeću verziju.

Posle toga ću ukratko pokazati napredni deo, gde sam svaki preostali propust rešio posebnom promenom i posebno ga izmerio: sečenje po rečenicama za E04 i E09 (7 → 9/12), viši prag odbijanja za E10 (9 → 10/12), semantička pretraga za E05 i E11 (10 → 12/12) i minimalna ocena citata (preciznost citata 1.00).

Na kraju ću objasniti cenu M5 filtera: sistem više nije mogao da odgovori kakva je bila stara politika. To sam rešio filterom koji poštuje verziju koju pitanje traži. Na dva nova skupa rezultat je porastao sa 9/20 na 20/20, na dva nova slepa skupa je 16/16, a od postojećih pitanja promenilo se samo jedno, Z07, koje je sa pogrešnog odbijanja prešlo na tačan odgovor. Ako bude vremena, pokazaću i pojačanu zaštitu od napada (6/10 → 10/10 na novom slepom skupu) i jednu promenu koju sam izmerio i odbio, jer je popravila jedno pitanje, a pokvarila dva.