Nedeljni izveštaj, Nedelja 7

Polaznik: Uroš Milutinović
Projekat: izvor. (kontrolisano poboljšanje RAG sistema)
Način rada: samostalno
Demonstraciju vodi: Uroš Milutinović
Pregled para: projekat sam poslao drugom polazniku na pregled (odeljak 9 izveštaja pre/posle)

Šta sam uradio

Prošao sam kroz propuste početnog sistema i za svaki zapisao konkretno pitanje iz eval skupa. Za obavezni deo izabrao sam M5, filter važeće verzije dokumenata (`CURRENT_ONLY`). Specifikaciju sam commitovao pre bilo kakve izmene koda (`2ceaced`), pa tek onda implementirao promenu (`45b8172`). Ceo projekat sam radio sam, uz AI asistenta kako je opisano u izveštaju.

Rezultat i dokazi

Na istih 12 pitanja rezultat je porastao sa 6/12 na 7/12, bez regresija. Na E06 sistem je ranije vadio staru politiku iz 2024. sa 2 dana rada od kuće, a sada vadi važeću iz 2026. sa 3 dana. Retrieval hit rate je sa 0,7778 porastao na 0,8889, a prosečna preciznost citata sa 0,4545 na 0,5455. Otisak eval skupa je isti pre i posle, a eval skup i kod za metrike nisam dirao.

U paketu su JSON rezultati pre i posle, izlaz poređenja, diff, specifikacija, izlazi testova (18 pre, 19 posle) i CLI izlazi za E06. Napredne eksperimente držim odvojeno u glavnom repou, jer nisu deo ove jedne promene.

Šta sam proverio i moj komentar

Proverio sam sve što je u izveštaju: propuste, specifikaciju i diff, rezultate pre i posle, poređenje, CLI odgovor i citate za E06 i ograničenja. Po mom mišljenju rezultati pokazuju da filter rešava izbor zastarele politike na E06. Ostale probleme sistema ne rešava.

I dalje ostaju problemi sa granicama chunkova, parafrazama, pitanjima na koja korpus nema odgovor i nebitnim drugim citatom. Filter ima i cenu: sistem više ne može da odgovori kakva je bila stara politika, a osnovni eval to ne meri. Svaki od ovih problema traži posebnu promenu i novo merenje, pa sam ih rešavao u naprednom delu, odvojeno od M5.

Korišćenje AI-ja

AI mi je pomagao u analizi, pisanju nacrta specifikacije i izveštaja, implementaciji i pokretanju provera. I ovaj tekst sam pisao uz njegovu pomoć. Zaključke sam proverio sam, na sačuvanim rezultatima, u kodu i ručnim pokretanjem CLI-ja.

Plan demonstracije za Sesiju 2

Počeću od propusta na E06, gde sistem odgovara iz zastarele politike. Onda ću pokazati specifikaciju (`2ceaced`), diff promene (`45b8172`) i rezultate pre i posle na istom skupu, pa CLI izlaz koji sada citira važeću verziju. Na kraju ću objasniti zašto filter gubi istorijska pitanja i koji propusti ostaju posle ove jedne promene. Ukratko ću pokazati i kako

sam ih rešio u naprednom delu, gde je svaka promena merena posebno: sečenje po rečenicama (7 → 9/12), viši prag odbijanja (9 → 10/12), semantička pretraga (10 → 12/12) i minimalna ocena citata (preciznost citata 1.00).